

Corpus Paths (relative to src/)

train.en

data/train.en

train.hi

data/train.hi

**Training**

Max training pairs

500000

IBM1 EM iterations

10

Phrase extraction pairs

300000

Max phrase length

5

Random seed

# EN→HI Statistical Machine Translation (SMT)

IBM Model 1 word alignment → phrase extraction → phrase table → bigram Hindi LM → noisy-channel decoding

**Step 1 – Load a saved model (fast) OR Train a new model**

Load Model

Train Model

Save Model

## System Requirements Output

Sentence pairs

500000

EN vocab

87593

HI vocab

124985

HI LM vocab

124987

IBM iters: 10 | Phrase pairs: 300000 | Max phrase len: 5 | Build sec: 2496.56

## Top learned lexical translation

## probabilities: t(hi|en)

**the** → के (0.130), की (0.096), को (0.086), है (0.085), में (0.063), और (0.062), का (0.060), , (0.043)

**and** → और (0.648), ( (0.037), ) (0.036), की (0.024), भी (0.020), को (0.019), से (0.018), है (0.017)

**of** → की (0.202), के (0.169), का (0.132), से (0.091), में (0.046), और (0.040), है (0.029), ( (0.026)

**to** → को (0.136), के (0.118), लिए (0.086), में (0.068), की (0.055), कि (0.049), है (0.048), करने (0.048)

**is** → है (0.565), है। (0.074), वह (0.026), ( (0.023), ) (0.023), और (0.023), तो (0.020), यह (0.020)

**in** → में (0.594), के (0.048), है (0.033), और (0.033), की (0.033), पर (0.026), से (0.022), जो (0.017)

**a** → एक (0.311), के (0.090), है (0.068), की (0.043), से (0.039), का (0.033), को (0.031), कोई (0.029)

**you** → तुम (0.399), हो (0.104), तो (0.052), आप (0.045), ( (0.037), ) (0.037), कि (0.029), से (0.026)

# Translate (Noisy Channel Decoding)

English input

there is a door

Translate

Translation completed.

HYP: एक द्वार

TM log: -3.902 | LM log: -22.859 | Total: -31.332